

Automatisation de traitements de données cinématographiques : nettoyage, structuration et analyse par KPI

Losseni ZOURI

1 Contexte général du projet

Ce projet a consisté à développer, en Python, une chaîne de traitement automatisée permettant de transformer des données cinématographiques brutes et non structurées en un livrable exploitable pour l'analyse. Le point de départ est un fichier texte brut regroupant les informations d'un ensemble de films sous une forme peu lisible et non tabulaire. L'objectif était double :

- produire un fichier CSV propre et structuré, directement exploitable dans un tableur (Excel) ou par un autre programme ;
- générer un rapport analytique synthétique fournissant des indicateurs clés de performance (KPI) sur l'ensemble des films traités (notes moyennes, répartition par genre, etc.).

L'enjeu principal résidait dans la robustesse du traitement : le script devait être capable de lire un fichier texte au format libre, d'en extraire les champs pertinents malgré des incohérences de saisie (espaces, virgules superflues, casse variable), puis de convertir chaque valeur dans le type de donnée adapté avant de produire les fichiers de sortie.

2 Organisation et outils utilisés

Le projet repose exclusivement sur la bibliothèque standard de Python, sans dépendance externe, conformément aux contraintes de l'exercice :

Lecture / écriture de fichiers : gestion native des fichiers via `open()`, avec un encodage adapté à chaque étape (utf-8 en lecture, cp1252 en écriture pour la compatibilité Excel).

Traitement de chaînes de caractères : `split()`, `find()`, `strip()` et `rstrip()` pour découper le texte brut, isoler les champs et supprimer les caractères indésirables.

Structuration des données : organisation des champs extraits dans des listes, puis conversion aux types adéquats (int, float, str).

Analyse : fonctions dédiées au calcul des indicateurs statistiques (score minimum, maximum, moyen, taux de films par genre).

Le script est organisé en quatre étapes séquentielles clairement délimitées par des commentaires : lecture du fichier source, extraction et typage des champs, écriture du CSV, puis calcul et écriture des indicateurs dans un fichier d'informations.

3 Description des données

Les données sources proviennent d'un fichier texte (groupe12E_data.txt) dans lequel chaque film est séparé par le caractère « % » et chaque champ est identifié par une étiquette du type champ=valeur. Ce format, non standard, nécessite un parsing spécifique avant toute exploitation.

Format source	Fichier texte (.txt), séparateur de films « % », champs sous forme clé=valeur
Format cible	Fichier CSV structuré (séparateur « ; »), encodage cp1252
Champs extraits	title, nbvotes, score, duration, year, type, restriction, desc
Champs du CSV final	Référence, Titre, Durée, Année, Restriction, Nombre de votes, Score, Description

Tableau 1 — Structuration des données brutes vers le format tabulaire final

Chaque film se voit attribuer une référence unique construite selon le format F-<groupe>-<compteur>-<année>, ce qui permet d'identifier et de tracer chaque enregistrement dans le fichier final.

4 Traitement automatisé en Python

4.1 Extraction et typage des champs

Le texte brut est d'abord découpé en une liste de films grâce à `split("%")`, puis nettoyé des chaînes vides générées par les séparateurs successifs. Pour chaque champ, le script localise la position de l'étiquette (ex. "score=") et extrait la sous-chaîne jusqu'à l'étiquette suivante :

```
list_films = text.split("%")

for i in range(len(champs)):
    for film in final_list:
        champ = champs[i]
        start = film.find(champ+"=") + len(champ) + 1
        if i < (len(champs) - 1):
            end = film.find(champs[i+1]+"=", start)
        else:
            end = len(film)
        res = film[start:end].strip()
        films_dataset[i].append(res)
```

Chaque valeur extraite est ensuite reconvertie dans le type approprié : entier pour le nombre de votes et l'année, réel pour le score, chaîne normalisée (`title()`) pour le titre et la restriction. Cette étape garantit la cohérence des données avant écriture et calcul des indicateurs.

4.2 Écriture du CSV structuré

Une fois les données typées, le script génère une référence unique par film puis écrit chaque enregistrement dans un fichier CSV, ligne par ligne, avec un séparateur point-virgule adapté à l'ouverture directe sous Excel en français :

```
ref = f"F-{groupe}-{compteur}-{final_dataset[4][i]}"
ligne = [ref, final_dataset[0][i], final_dataset[3][i],
        final_dataset[4][i], final_dataset[6][i],
        final_dataset[1][i], final_dataset[2][i], final_dataset[7][i]]
result.write(';'.join(str(x) for x in ligne) + '\n')
```

4.3 Calcul des indicateurs (KPI)

Le rapport analytique s'appuie sur des fonctions dédiées, écrites sans bibliothèque externe, qui parcourent les données déjà structurées pour en extraire des indicateurs statistiques :

```
def score_mean(data):
    total = 0.0
    score = data[2]
    for d in score:
        total += d
    return round(total/len(score), 2)

def drama_percent(data):
    types = data[5]
    total = 0
    for d in types:
        genres = [g.strip().lower() for g in d.split('|')]
        if 'drama' in genres:
            total += 1
    return round((total/len(types)*100), 2)
```

Les genres étant stockés sous forme de chaîne concaténée (séparateur « | »), chaque valeur est découpée puis normalisée en minuscules avant comparaison, ce qui rend le calcul robuste aux variations de casse ou d'espacement dans la source.

5 Résultats clés (KPI)

À l'issue du traitement, un fichier d'informations (groupe12E_infos.txt) est généré automatiquement. Il synthétise, pour l'ensemble du jeu de données traité, les indicateurs suivants :

Indicateur	Description
Nombre de films	Nombre total d'enregistrements traités depuis le fichier source
Score minimum	Note la plus basse observée dans le jeu de données
Score maximum	Note la plus élevée observée dans le jeu de données
Score moyen	Moyenne arithmétique des notes, arrondie à 2 décimales
Taux de drames	Part des films classés dans le genre « Drama », en %
Taux de films d'action	Part des films classés dans le genre « Action », en %

Tableau 2 — Indicateurs générés automatiquement dans le fichier d'informations

Ces indicateurs sont recalculés automatiquement à chaque exécution du script : toute mise à jour du fichier source (ajout ou modification de films) se répercute directement sur le CSV structuré et sur le rapport de KPI, sans intervention manuelle.

6 Conclusion

Ce projet a permis de mettre en œuvre, de bout en bout, une chaîne de traitement de données textuelles en Python : lecture de fichier, parsing d'un format non structuré, typage et nettoyage des valeurs, écriture d'un livrable tabulaire, puis calcul d'indicateurs analytiques. Il illustre la capacité à transformer une source de données brute et hétérogène en un livrable directement exploitable (CSV structuré) et en un rapport de synthèse orienté décision (KPI), sans recourir à des bibliothèques externes de traitement de données.

Au-delà de l'aspect technique, ce travail a renforcé la maîtrise des manipulations de chaînes de caractères, de la gestion des fichiers et de l'écriture de fonctions d'analyse réutilisables — des compétences directement transférables à des contextes de préparation de données (data cleaning) en amont d'outils de dataviz tels qu'Excel ou Power BI.